

MAKİNE ÖĞRENMESİ İLE E-TİCARET ÜRÜN YORUMLARININ ANALİZİ

AHMET EMRE ZAVAR ABDURRAHMAN DEMİR

Elektronik ve Elektronik Mühendisliği

Isparta Uygulamalı Bilimler Üniversitesi

(12322705052@isparta.edu.tr) (12322705030@isparta.edu.tr)

Öz-Bu çalışmada, Türkçe müşteri geri bildirimlerini duygu durumuna göre sınıflandırılmasını yarayan bir makine öğrenmesi çalışması tasarlanmıştır. Çalışmanın temel gayesi, kullanıcıların olumlu, olumsuz ve nötr içerikleri kolayca tespit edebileceği, etkileşimli ve özelleştirilebilir bir sistem ortaya koymaktır. Derin öğrenme yöntemlerinden LSTM (Long Short-Term Memory) mimarisi tercih edilerek, metin verilerindeki ilişkiler dikkate alınmış ve yüksek doğruluk oranı hedeflenmiştir. Modelin geliştirme aşamasında, açık kaynaklı bir yapay zeka kütüphanesi olan TensorFlow yararlanılmıştır. TensorFlow'un esnek yapısı, modelin verimli bir şekilde eğitilmesini ve değerlendirilmesini sağlamıştır.

Çalışma, Python dili ile kodlanmış; kullanıcı arayüzü ise tkinter kütüphanesiyle oluşturulmuştur. Eğitim ve test aşamalarında elde edilen neticeler, sistemin Türkçe dilinde etkili bir duygu analiz aracı olduğunu sunmaktadır. Ortaya konan sistem, hem akademik araştırmalarda hem de gerçek hayattaki metin işleme uygulamalarında kullanılabilecek düzeydedir.

Anahtar Kelimeler: Duygu Analizi, Ürün Yorumları, LSTM, TensorFlow, Derin Öğrenme

I.GİRİŞ

Dijitalleşmenin yaygınlaşmasıyla birlikte, e-ticaret platformları üzerinden yapılan alışverişlerde müşteri geri bildirimleri önemli bir karar verme aracı haline gelmiştir. Tüketici geri bildirimleri, ürünlerin kalitesi, işlevselliği ve hizmet memnuniyeti hakkında bilgi sunarken; bu yorumların sayısal olarak değerlendirilmesi, firmalar ve müşteriler yönünden analiz edilmesi gereken büyük bir veri kaynağı ortaya çıkarmaktadır. Bunun sonucunda, doğal dil işleme (NLP) ve makine öğrenmesi yöntemlerinden yararlanılarak metin tabanlı içeriklerin otomatik sınıflandırılması, literatürde yaygın olarak ele alınan bir problem olarak kendini göstermektedir.

Bu çalışmada, Türkçe e-ticaret yorumlarının duygusal içeriği baz alınarak sınıflandırılması hedeflenmiştir. Yorumlar, üç temel duygu kategorisine (olumlu, olumsuz, nötr) ayrılarak analiz edilmiştir. Bu doğrultuda, yapay sinir ağları tabanlı Long Short-Term Memory (LSTM) mimarisi kullanılarak derin öğrenme temelli bir sınıflandırma modeli tasarlanmıştır. LSTM modeli, metin verilerindeki zamansal ilişkileri öğrenebilme yeteneği sayesinde, dildeki duygusal geçişleri daha başarılı bir şekilde yakalayabilmektedir.

Modelin eğitimi için hem açık kaynaklı platformlardan temin edilen etiketli yorumlar hem de yapay zeka destekli yöntemlerle oluşturulan ek veri örnekleri birleştirilmiştir. Veri setinin çeşitliliği, modelin genelleme kapasitesini artırmaya yönelik bir strateji olarak ele alınmıştır. Python programlama dili kullanılarak geliştirilen modelde; TensorFlow, Keras, Scikit-learn ve ilgili doğal dil işleme kütüphanelerinden faydalanılmış; arayüz tasarımı ise tkinter kütüphanesi aracılığıyla yapılmıştır.

Tasarlanan sistem, yalnızca yüksek doğruluk oranlarıyla duygu sınıflandırması yapabilen bir yapı sunmakla kalmamakta, aynı zamanda kullanıcı etkileşimine açık bir grafik arayüz ile desteklenerek pratik bir kullanım imkânı da sağlamaktadır. Makalenin devamında, sistemin geliştirme süreci, kullanılan yöntemler, deneysel analizler ve sonuçların değerlendirilmesine ilişkin detaylara yer verilmektedir.

II.LİTERATÜR TARAMASI

Yücelar ve arkadaşları yaptıkları çalışmada , Türkçe e-ticaret ürünlerindeki müşteri geri bildirimlerini duygu analizi ile ele almıştır. İlk aşamada 15.170 müşteri geri bildirimini elle etiketleyip bir LSTM modeli tasarlamışlar , bu modelle de 200 binden fazla müşteri geri bildirimini etiketlemişlerdir. Bunun ardından makine öğrenmesi ve derin öğrenme yöntemlerini karşılaştırmışlar ve derin öğrenmenin daha iyi sonuçlarının olduğunu gözlemlemişlerdir [1].

Kılıçer ve Samli , yaptıkları çalışmada 11.412 adet Türkçe e-ticaret elektronik cihaz müşteri geri bildirimlerini pozitif , negatif ve nötr olarak ayırmak için sekiz farklı makine öğrenmesi algoritmasını kullanmışlardır. Yaptıkları bu kıyasda, NBM ve RO algoritmalarının en yüksek AUC değerlerini sağladığı , NBM'nin ise ağırlıklı ortalamada %84.6 AUC ve %69.7 doğru sınıflandırma oranı ile en iyi başarıyı gösterdiği tespit edilmiştir [2].

Göçgün ve Onan , Amazon müşteri geri bildirimlerindeki duygu analizleri (olumlu , olumsuz , nötr) belirlemek üzere çalışmıştır. Kaggle platformundan temin ettikleri 28 binden fazla müşteri geri bildiriminin Naive Bayes , SVM , Karar Ağacı ve Lojistik Regresyon algoritmalarıyla analiz etmişlerdir. Yorumların derece skalasına göre duygu tespiti yapıldıktan sonra , Karar Ağacı algoritmasının %94 doğruluk ve %96 AUC ile en iyi sonuca ulaşıldığı görülmüştür [3].

Zada ve Albayrak , Türkiye’deki bir e-ticaret platformundan elde ettikleri 2237 müşteri geri bildirimini duygu analizi ve topluluk öğrenmesi yöntemleriyle değerlendirmiştir. Yorumlardaki duygusal ifadeler VADER yöntemiyle çözümlenmiş , elde edilen sonuçlar kullanıcıların yıldız puanlarıyla olan ilişkisi Random Forest ve AdaBoost algoritmaları aracılığıyla incelenmiştir. Araştırma , müşteri geri bildirimi ve puanlar arasında bir uyumsuzluğun olduğunu ve en yüksek uyumun dört yıldız puanı alan müşteri geri bildirimlerinde (%87.9 Random Forest ile) tespit edildiğini sunmuştur [4].

Sayghn ve SAVAŞ , yaptıkları çalışmada Amazon ürün yorumlarındaki tüketici geri bildirimlerindeki duygusal içeriği incelemek üzere makine öğrenmesi ve derin öğrenme yöntemlerinin performansını kıyaslamıştır. 15.000’den fazla yorum barındıran bir veri seti üzerinde SVM , Karar Ağacı , Knn ve LSTM algoritmalarını test etmişlerdir. Sonuçlar , LSTM modelinin %98 doğruluk oranı ile en iyi başarıyı gösterdiğini , Karar Ağacının ise %77.8 doğruluk ile en kötü performansı vermiştir. Bu durum , LSTM’in karmaşık metinlerde daha başarılı olduğunu göstermektedir [5].

Tabany ve Gueffal , Amazon müşteri geri bildirimlerinin duygu analizi ve sahte yorumların saptanması için SVM modeli tercih edilmiştir. Çalışmalarında SVM’in duygu analizinde Naive Bayes , Lojistik Regresyon ve Rastgele Orman’a kıyasla daha iyi performans gösterdiği (%70 ham , %93 ayarlanmış doğruluk) tespit edilmiştir. Ayrıca , yorum metin uzunluğunun SVM performansını etkilediği , kısa yorum metinlerinin %95 doğrulukla , 200 kelimeden uzun yorum metinlerinin ise %84 doğrulukla ayrıştırılabildiği ortaya konmuştur. Bilgisayar tarafından üretilmiş sahte yorumların tespitinde ise SVM %88’lik bir doğruluk oranı yakalamışlardır[6].

Harunasir vd. , Amazon ürün yorumları üzerinden kontrollü makine öğrenimi modellerini kıyaslayarak duygu analizi yapmıştır. Bilhassa , yüksek yıldız derecelendirmesine sahip fakat olumsuz etiketler içerebilen yorumlar üzerinde durulmuştur. 34.000’i aşkın yorumu kapsayan bir veri seti üzerinde Multinomial Naive Bayes (MNB), Random Forest (RF), Long-Short Term Memory (LSTM) ve Convolutional Neural Network (CNN) algoritmalarını uygulamışlardır. Sonuçlar , LSTM modelinin %97 doğruluk oranıyla diğer modellerden daha iyi performans göstermiştir [7].

Haroon vd. , e-ticaret sitelerindeki müşteri geri bildirimlerinin duygu analizi için Lojistik Regresyon , Naive Bayes , Sinir Ağları ve destek vektör makinesi (DVM) algoritmalarını kıyaslamışlardır. Bir e-ticaret sitesinden elde edilen 19.663 yorumu kapsayan veri seti , doğal dil işleme (NLP) ve VADER duygu analiz aracından yararlanarak pozitif negatif , nötr olarak etiketlenmiştir. Yapılan incelemeler neticesinde Naive Bayes modelinin %94 doğrulukla diğerlerinden daha iyi performans gösterdiği tespit edilmiştir. Lojistik Regresyon ve

Sinir Ağları %93 doğruluk sağlarken , DVM %92 oranında bir doğruluk yakalamıştır [8].

Tuna , Kaynar ve Akdoğan , TripAdvisor.com sitesinden temin edilen otel müşteri geri bildirimlerini içeren bir veri setinde , yedi farklı makine öğrenmesi algoritması (Lojistik Regresyon , Random Forest , CART Sınıflandırıcısı , K-En Yakın Komşu , Destek Vektör Makineleri , Doğrusal Diskriminant Analiz Sınıflandırıcısı ve Naive Bayes) kullanarak duygu analizi yapmışlardır. Antalya şehrindeki otellere ait 7117 yorum , müşterilerin oyladığı puanlara göre pozitif veya negatif olarak etiketlenmiş Zemberek Türkçe NLP kütüphanesi ile ön işlemlerden geçirilmiştir. Çalışmada kullanılan yöntemlerin ortalama başarısı %81.3 olarak hesaplanmış , Lojistik Regresyon algoritmasının da %87.99 F-ölçümü ile en başarılı performansı sergilemiştir [9].

Singhal ve arkadaşları , Amazon’dan alınan 400.000’den fazla cep telefonu değerlendirmesi üzerinde denetimli makine öğrenimi yollarıyla duygu analizi gerçekleştirmiştir. Yorumlar yıldız derecesine göre pozitif ve negatif olarak etiketlenmiş ve eğitim için 194.050 yorumluk dengeli bir veri seti kullanılmıştır. Özellik çıkarımı için Bag-of-Words ve n – gram (unigram , bigram , trigram kombinasyonu) yöntemleri kullanılmıştır. Karar Ağacı Naive Bayes , Rastgele Orman ve DVM sınıflandırıcıları kıyaslanmış ve Rastgele Orman modelinin %97.48 doğruluk payı ile en çok başarı oranını yakalamıştır [10].

III.MATERYAL VE YÖNTEM


3.1 Kullanılan Veri Seti

Bu çalışmada , müşteri geri bildirimlerini duygu (sentiment) durumuna göre sınıflandırılması maksadı ile veri seti kullanılmıştır. Veri seti kaynağı Github dan hazır alınarak ve yapay zekadan da yardım alınarak hazırlanmıştır. Veri seti adet 3093 ürün yorumunu içermektedir ve yapılan her bir geribildirim, doğru , yanlış ve nötr şeklinde etiketlenmiştir. Veri setinde , doğru , yanlış ve nötr tanımlanan yorumlar gui kodlarının hazırlanması aşamasında doğru ise ekranda olumlu, yanlış ise ekranda olumsuz ve nötr ise ekranda nötr yazılması sağlanmıştır.

Veri kümesinde her satırda şu bilgiler yer almaktadır:

Yorum (Text): Müşterinin ürün hakkında yazdığı geri bildirimler.

Etiket (Label): 1 = Doğru , 0 = Yanlış , Nötr = 2




Şekil 1. Veri Seti Kullanılarak Oluşturulan Yorum Sayısı ve Yorum Türü Grafiği.

3.2 Veri Ön İşleme (Preprocessing)

Bu çalışmada kullanılan veri seti hazır olarak alınmış olup, her bir ürün yorumuna ait duygu etiketi önceden atanmıştır. Ancak, modelin daha sağlıklı sonuçlar verebilmesi adına veriler üzerinde bazı ön işleme adımları gerçekleştirilmiştir: Metinlerin küçük harfe dönüştürülmesi: Büyük-küçük harf farkından kaynaklı tutarsızlıkları önlemek amacıyla tüm yorumlar küçük harfe çevrilmiştir. Noktalama işaretlerinin temizlenmesi: Cümlelerde yer alan gereksiz noktalama işaretleri kaldırılmıştır. Anlamsız ve çok kısa yorumların dışlanması: Yeterli bilgi içermeyen veya çok kısa olan metinler değerlendirme dışı bırakılmıştır.

Gerçekleştirilen işlemler sonucunda, metinler daha açık ve işlenebilir hâle getirilmiş; bu sayede modelin öğrenme süreci için daha uygun bir yapı kazandırılmıştır.



Şekil 2. Programın Gui Arayüz Tasarımı.

3.3 Kullanılan Araçlar ve Kütüphaneler

Bu projede, ürün değerlendirmelerini sınıflandırmaya yönelik işlemlerde Python dili ve çeşitli veri işleme ile derin öğrenme kütüphanelerinden faydalanılmıştır. Veriler, Pandas aracılığıyla sisteme alınarak temizlenmiş ve metinsel içerikler, Keras'ın Tokenizer modülüyle sayısal forma çevrilmiştir. Bu dönüşüm, modelin sabit boyutlu girdi isteğini karşılayacak şekilde uygulanmıştır. Ardından, kelime sıralarındaki anlamsal ilişkileri öğrenebilmek amacıyla LSTM tabanlı bir yapay sinir ağı modeli tasarlanmış ve bu yapı TensorFlow/Keras çatısı altında eğitilmiştir. Eğitim aşamasında aşırı öğrenmeyi engellemek için erken durdurma yöntemi ile sınıf dengesizliklerine karşı sınıf ağırlıkları tanımlanmıştır. Modelin doğruluğu ve sınıflandırma başarısı Scikit-Learn üzerinden elde edilen değerlendirme metrikleriyle ölçülmüştür. Ayrıca, kullanıcı ile etkileşimli çalışabilmesi için görsel arayüz kısmı Tkinter kütüphanesiyle oluşturulmuştur.

3.4 Model Mimarisinin Geliştirilmesi

Bu çalışmada metin tabanlı duygu sınıflandırması için derin öğrenme yaklaşımı tercih edilmiş ve TensorFlow çatısı altında LSTM (Long Short-Term Memory) katmanları kullanılarak bir model geliştirilmiştir. İlk olarak veri setindeki yorumlar gerekli ön işlemlerden geçirilerek sadeleştirilmiş, ardından sayısal hale getirilmesi için Keras Tokenizer aracıyla sayısal verilere dönüştürülmüştür. Bu diziler aynı uzunluğa getirilerek modele giriş olarak verilmiştir. Modelin ilk katmanında kelime anlamlarını temsil edebilmek amacıyla bir embedding yapısı kullanılmıştır. Daha sonra gelen LSTM katmanı, kelimeler arasındaki ilişkiyi öğrenmeye çalışmış ve bunu temel alarak yorumun taşıdığı duygu hakkında tahminde bulunmuştur. Son katmanda ise sınıflandırma işlemini gerçekleştiren bir yoğun bağlantılı katman (dense layer) yer almıştır. Eğitim süreci boyunca modelin aşırı öğrenmesini engellemek için dropout gibi yöntemler uygulanmış ve doğrulama verileri üzerinden performans takibi yapılmıştır. Modelin genel başarımı ise doğruluk (accuracy), F1 skoru gibi ölçütlerle değerlendirilmiştir.

IV.SONUÇLAR VE TARTIŞMA

Modelin eğitimi ve test edilmesi sonucunda elde edilen performans ölçütleri aşağıda verilmiştir. Aşağıdaki tablolarda kullanılan değerlendirme metriklerinin tanımlamaları ;


Değerlendirme metriklerinden Kesinlik (Precision) modelin belirli bir duygu sınıfı olarak etiketlediği yorumların gerçekte ne kadarının o sınıfa ait olduğunu gösterirken ; Duyarlılık (Recall) ilgili sınıfa ait tüm gerçek yorumların model tarafından ne kadarının doğru tespit edilebildiğini ölçer. Bu iki metriğin harmonik ortalaması olan F1-Skoru , kesinlik ve duyarlılık arasında bir denge kurarak modelin genel sınıflandırma başarısını ortaya koyar. Son olarak , Destek (Support) ise her bir duygu sınıfı için veri setinde olan gerçek örnek sayısını ifade ederek diğer metriklerin hangi örneklem

büyüklüğü üzerinde hesaplandığına dair önemli bir sonuç verir. Modelin genel Doğruluk (Accuracy) oranı, tüm yorumlar arasında doğru tespit edilen sınıflandırmaların yüzdesini gösterir. Sınıf bazlı metriklerin özetlenmesinde ise Makro Ortalama, her duygu sınıfının performansına eşit ağırlık verirken; Ağırlıklı Ortalama, her sınıfın metrik değerini o sınıftaki yorum sayısına göre ağırlıklandırarak genel bir skor hesaplar ve böylece sınıf dağılımının etkisini gösterir.

TABLO 1
TEST METRİK DEĞERLERİNİN ÖLÇÜM TABLOSU

Algoritma Adı	Doğruluk (Accuracy)	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru
TensorFlow LSTM	0.88	0.89	0.88	0.88


Model performansının değerlendirilmesinde kullanılan temel metrikler, sistemin genel başarısını ve farklı açılardan üstünlüğünü ortaya koyar. Doğruluk (Accuracy), modelin tüm kategorilerdeki örnekler için yaptığı doğru sınıflandırmaların toplam örnek sayısına oranını ifade eder. Kesinlik (Precision) metriği, modelin belirli bir sınıf için pozitif olarak etiketlediği örnekler arasında gerçekten o sınıfa ait olanların oranını belirtirken; Duyarlılık (Recall) ise gerçekte belirli bir sınıfa ait olan örneklerden ne kadarının model tarafından doğru bir şekilde tanınabildiğini gösterir. Bu iki metriğin harmonik ortalaması olan F1-Skoru ise, özellikle sınıflar arası dengesizlik durumlarında modelin genel performansını daha dengeli bir şekilde ölçmek için kullanılır. Ağırlıklı ortalama değerleri ise, her bir sınıfın veri setindeki büyüklüğünü dikkate alarak bu metriklerin genel bir özeti sunar.




Şekil 3. Modelin Doğruluk Geçmişi Grafiği.

Epoch, makine öğrenmesinde, modelin tüm eğitim veri setini baştan sona bir kez işlemesi anlamına gelir. Kayıp, modelin eğitim süreci boyunca (epoch'lar ilerledikçe) hem eğitim verilerinde hem de validasyon verilerinde ne kadar hata yaptığını gösterir. Amaç, bu kayıp değerini mümkün


olduğunca düşürerek modelin daha doğru tahminler yapmasını sağlamaktır.




Şekil 4. Modelin Kayıp Geçmişi Grafiği.



Şekil 5. Çok Sınıflı ROC Eğrileri.



Şekil 6. Karışıklık Matrisi (Eğitim).



Şekil 7. Karışıklık Matrisi (Test).

4.1 GENEL DEĞERLENDİRME: EĞİTİM VE TEST PERFORMANSI KARŞILAŞTIRMASI

Bu projede derin öğrenme temelli Bi-LSTM modeli müşteri kullanıcı yorumları Olumlu, Olumsuz ve Nötr şeklinde sınıflandırılmıştır. Modelin test verisi üzerindeki genel başarısı oldukça tatmin edici seviyededir. Elde edilen doğruluk oranı %88.21 olup, modelin yeni verilerle çalışırken büyük oranda doğru tahminler yapabildiğini göstermektedir. F1-skorları incelendiğinde, Olumlu yorumlarda %92, Olumsuz yorumlarda %89, ve Nötr yorumlarda %74'lık değerler elde edilmiştir. Bu da modelin özellikle güçlü duygular içeren yorumları doğru şekilde ayırdığını, ancak daha belirsiz olan nötr ifadelerde kısmen zorlandığını göstermektedir.

Karmaşıklık matrisine bakıldığında da modelin genel eğilimleri net bir şekilde görülmektedir. Özellikle Olumlu ve Olumsuz yorumlar çoğunlukla doğru sınıflandırılırken, Nötr sınıfta bir miktar karışıklık olduğu görülmüştür. Bunun ana nedeni, nötr yorumların dil açısından daha belirsiz ve yorumlamaya açık olmasıdır. Bu gibi sınıflarda verinin artırılması ya da modelin dikkat mekanizması gibi yöntemlerle desteklenmesi fayda sağlayabilir.

Test kaybı değeri olan 0.3672, modelin tahminlerinde çok büyük sapmalar yaşamadığını ve oldukça tutarlı çalıştığını ortaya koymaktadır. Ayrıca eğitim sırasında erken durdurma gibi yöntemler kullanılarak aşırı öğrenmenin önüne geçilmeye çalışılmıştır. Eğitim ve test sonuçları arasında büyük bir uçurum olmaması da bu yöntemin işe yaradığını göstermektedir.

Sonuç olarak, geliştirilen Bi-LSTM modeli yorum sınıflandırmada genel olarak başarılıdır. Özellikle olumlu ve olumsuz yorumları ayırt etme konusunda yüksek doğruluk sağlarken, nötr ifadelerle ilgili başarı düzeyi de kabul edilebilir seviyededir. Modelin şu anki haliyle pratik uygulamalarda kullanılabilecek bir performans gösterdiği söylenebilir; ancak daha dengeli sınıf dağılımı veya gelişmiş modellerle performansın daha da artırılması olasıdır.

4.2 Elde Edilen Sonuçların Literatürdeki Çalışmalarla Doğrudan Karşılaştırılması

Metin tabanlı duygu analizi için TensorFlow ve Çift Yönlü LSTM mimarisi kullanan özgün bir derin öğrenme modeli geliştirilmiştir. Modelin test verileri üzerindeki sınıflandırma başarısı incelenmiştir. Sistem, test setinde %88.21 genel doğruluk oranına ulaşırken, sınıflar arası performans dengesini yansıtan Makro Ortalama F1-skoru %85 olarak tespit edilmiştir. Bu temel göstergeler, geliştirilen derin öğrenme yaklaşımının, alandaki geleneksel metotlarla rekabetçi sonuçlar ürettiğini göstermektedir.

TABLO 2
LİTERATÜRDEKİ ÇALIŞMALAR VE BU ÇALIŞMANIN KIYASI

Yazar(lar)	Yöntem(ler)	Veri Sayısı	Doğruluk (%)	En Başarılı Algoritma
Bu Çalışma	TensorFlow LSTM	3093	88.21	TensorFlow LSTM
Yücelar vd.	LSTM	200,000	-	LSTM
Kılıçer & Samli	NBM, RO, 8 algoritma	11,412	69.7	NBM
Göçgün & Onan	NB, SVM, LR, DT	28,000+	94.0	Karar Ağacı
Zada & Albayrak	VADER + RF, AdaBoost	2237	-	Random Forest
Saygıhı & Savaş	SVM, KNN, DT, LSTM	15,000+	98.0	LSTM
Tabany & Gueffal	SVM, NB, LR, RF	-	93.0	SVM
Harunasir vd.	MNB, RF, LSTM, CNN	34,000+	97.0	LSTM
Haroon vd.	LR, NB, DVM, ANN	19,663	94.0	Naive Bayes
Tuna vd.	7 ML algoritması	7117	-	LR (F1 = 87.99)
Singhal vd.	DT, NB, RF, SVM	400,000	97.48	Random Forest

Mevcut analiz, 3093 yorumdan oluşan, tabloda yer alan diğer bazı akademik çalışmalara nispeten daha kısıtlı ve dengeli olduğu varsayılan bir veri kümesi üzerinde yürütülmüş olup, %88.21 düzeyinde bir genel doğruluk skoruna ulaşmıştır. Tabloda sunulan diğer çalışmalarla bir mukayese yapıldığında, bazı yaklaşımların daha geniş veri setleri veya farklı algoritmik tercihlerle (örneğin, Göçgün & Onan'ın Karar Ağacı uygulamasıyla %94 doğruluk veya Sayghın & Savaş'ın yine LSTM kullanarak %98 doğruluk) daha yüksek başarı oranları sergilediği görülmektedir. Bununla birlikte, mevcut çalışmamızın daha sınırlı bir veri hacmiyle elde ettiği bu sonuç, kullanılan derin öğrenme yöntemi kayda değer bir başarıyı ulaşmıştır. Özellikle, geleneksel makine öğrenmesi tekniklerini kullanan ve tabloda daha düşük doğruluk oranları raporlayan bazı çalışmalara (örneğin, Kılıçer & Şamlı tarafından NBM ile elde edilen %69.7'lik doğruluk) kıyasla, geliştirilen modelin sergilediği performans dikkat çekicidir. Bu durum, uygulanan LSTM tabanlı sistemin, veri kısıtlılığı olan senaryolarda bile güvenilir ve rekabetçi sonuçlar üretebileceğini düşündürmektedir.

4.3 Çalışmanın Yorumlanması :

Bu çalışma kapsamında, Türkçe çevrimiçi ürün değerlendirmelerinden duygu sınıflarını (Pozitif, Negatif, Nötr) çıkarmak amacıyla TensorFlow altyapısı üzerinde bir Çift Yönlü Uzun Kısa Süreli Bellek (Bidirectional LSTM) ağı tasarlanmış ve uygulanmıştır. Geliştirilen bu derin öğrenme modelinin, daha önce karşılaşmadığı test örnekleri üzerinde sergilediği performans incelendiğinde, %88.21 gibi dikkate değer bir genel doğruluk (accuracy) seviyesine ulaştığı gözlemlenmiştir. Bu sonuç, modelin Türkçe metinlerde ifade edilen duygu sinyallerini önemli bir isabet oranıyla tespit etme yeteneğine işaret etmektedir.

Modelin genel başarısının yanı sıra, temel duygu kategorileri olan 'Olumlu' ve 'Olumsuz' ifadelerin sınıflandırılmasında özellikle iyi olduğu görülmüştür. 'Olumlu' sınıfı için %92 F1-skoru ve %89 duyarlılık, 'Olumsuz' sınıfı için ise %89 F1-skoru ve %90 duyarlılık gibi yüksek değerler, modelin bu iki zıt kutbu birbirinden etkin bir şekilde ayırt edebildiğini ortaya koymaktadır. Gelişmiş bir derin öğrenme mimarisi olan LSTM'in, mevcut veri kümesi üzerinde sınıf ağırlıklandırma gibi tekniklerle desteklenerek bu düzeyde bir başarıya ulaşması, seçilen yaklaşımın ve uygulanan veri ön işleme ile model optimizasyon süreçlerinin yerinde olduğunu göstermektedir.

Analizler sırasında, modelin 'Nötr' olarak etiketlenen yorumları ayırt etmede, diğer iki duygu sınıfına kıyasla bir miktar daha fazla zorlandığı tespit edilmiştir. 'Nötr' sınıfına ait test verilerindeki F1-skorunun (%74) ve duyarlılık değerinin (%79), 'Olumlu' ve 'Olumsuz' kategorilerine ait metriklerin bir miktar gerisinde kalması, nötr ifadelerin doğasında bulunan ve duygusal yoğunluğu daha az olan yapının, model tarafından tam olarak tespit edilmesinde bazı güçlükler oluşturabileceğini düşündürmektedir.

Dikkat çeken bir diğer konu, modelin eğitim verileri üzerinde elde ettiği doğruluk oranı (%97.78) ile validasyon (Validasyon, modelin aşırı öğrenmeyi önlemek için eğitim sırasında görmediği verilerle genelleme yeteneğinin test edilmesidir)(%86.77) ve test (%88.21) verileri üzerindeki doğruluk oranları arasında gözlemlenen farktır. Eğitim doğruluğunun validasyon ve test doğruluklarından belirgin şekilde yüksek olması, modelin eğitim verilerine bir miktar aşırı uyum (overfitting) gösterme potansiyeli taşıdığına ve genellemeyi daha da artırılabilirliğine işaret etmektedir. Bu durum, modelin karmaşıklığı, eğitim süresi veya regülarizasyon tekniklerinin daha hassas ayarlanması gibi faktörlerin gelecekteki iterasyonlarda gözden geçirilmesi için bir alan sunmaktadır.

4.4 Çalışmanın Sınırlı Kaldığı Yönleri :

Modelin ayrıntılı performansı incelendiğinde, 'Nötr' olarak etiketlenen yorumları ayırt etmede, diğer iki duygu sınıfına kıyasla bir miktar daha fazla zorlandığı görülmüştür. 'Nötr' sınıfına ait test verilerindeki F1-skorunun %74 ve duyarlılık değerinin %79 seviyesinde kalması, bu tür ifadelerin yapısında bulunan anlam belirsizliğinin veya modelin bu sınıfa özgü ayırt edici nitelikleri tam olarak benimseyememesinin bir sonucu olarak değerlendirilebilir. Sınıf ağırlıklandırma gibi tekniklerin kullanılmasıyla bu sınıftaki başarı bir miktar artsa da, 'Nötr' ifadelerin yapısı gereği bu zorluk devam etmektedir. Modelin genelleme kapasitesine ilişkin bir diğer önemli nokta, eğitim verileri üzerinde elde edilen %97.78'lik yüksek doğruluğa karşın, validasyon setinde %86.77 ve özellikle test setinde %88.21 doğruluk oranlarına ulaşılmasıdır. Eğitim setindeki bu üstün başarıya rağmen, modelin daha önce görmediği validasyon ve test verilerindeki performansındaki bu farklılık, bir düzeye kadar aşırı uyum (overfitting) eğilimi olabileceğine işaret etmektedir. Bu durum, modelin eğitim verilerindeki bazı spesifik örüntüleri ezberleyerek, yeni ve farklı veri yapılarına genelleme yapma yeteneğinin bir nebze kısıtlandığını düşündürmektedir.

Son olarak, Türkçe'nin zengin dil yapısı ve günlük dilde sıkça karşılaşılan ironi, mecaz gibi dolaylı anlatımlar, her ne kadar LSTM mimarisi bağlamsal bilgiyi yakalama yeteneğine sahip olsa da, modelin yorumlama kapasitesini zaman zaman zorlamış olabilir. Bu tür dilsel farklar, duygu analizi alanındaki genel bir zorluk olarak kabul edilmekte olup, modelimizin bu konudaki hassasiyetinin artırılması, gelecekteki iyileştirme amaçları arasında yer alabilir. Transformer tabanlı daha gelişmiş mimarilerin veya dil modeline özgü ön eğitimlerin yararlanılması, bu tür karmaşık dil yapılarının daha etkin bir şekilde işlenmesine katkı sağlayabilir.

V.SONUÇ

Bu çalışma kapsamında, Türkçe dilinde yazılmış ürün yorumlarındaki duygu eğilimlerini (Olumlu, Olumsuz, Nötr) otomatik olarak belirlemek amacıyla, TensorFlow ve Çift Yönlü Uzun Kısa Süreli Bellek (Bidirectional LSTM) ağlarını temel alan bir derin öğrenme yaklaşımı geliştirilmiş ve sonuçları detaylı bir biçimde analiz edilmiştir. Modelin tasarımında, kelime gömme (word embedding) katmanları aracılığıyla metinlerin anlamsal özelliklerinin tespit edilmesi ve ardından sınıf dengesizliğinin etkilerini azaltmak amacıyla sınıf ağırlıklandırma tekniğinin uygulanması esas alınmıştır.

Elde edilen deneysel bulgular, geliştirilen modelin hem öğrenme sürecinde kullanılan eğitim verileri üzerinde (%97.78 doğruluk), hem ara değerlendirme için ayrılan validasyon verileri üzerinde (%86.77 doğruluk) hem de modelin daha önce hiç karşılaşmadığı bağımsız test verileri üzerinde (%88.21 doğruluk) yüksek bir başarıyı gösterdiğini ortaya koymuştur. Özellikle, duygu analizi literatüründe genellikle sınıflandırılması daha zor olarak kabul edilen ve daha az belirgin özellikler taşıyan 'Nötr' sınıfında, test verileri üzerinde ulaşılan %79 duyarlılık ve %74 F1-skoru, modelin bu zorlu kategoride dahi dikkate değer bir ayırt etme yeteneğine sahip olduğunu göstermektedir.

Bu araştırmanın alana sunduğu temel katkılar birkaç başlık altında toplanabilir: İlk olarak, Türkçe gibi karmaşık morfolojik yapıya sahip dillerdeki kullanıcı yorumlarının duygu sınıflandırılması probleminde, Çift Yönlü LSTM gibi derin öğrenme mimarilerinin ve bu mimarileri destekleyici sınıf ağırlıklandırma gibi tekniklerin etkin bir şekilde kullanılabileceği deneysel olarak kanıtlanmıştır. İkinci olarak, modelin performans değerlendirmesi yalnızca genel doğruluk metriği ile sınırlı kalmamış; sınıf bazında Kesinlik (Precision), Duyarlılık (Recall), F1-Skoru ve bu metriklerin genel ortalamalarını içeren Karışıklık Matrisi gibi detaylı analizlerle modelin güçlü ve zayıf yönleri çok boyutlu bir bakış açısıyla ortaya konmuştur. Üçüncü olarak, özellikle 'Nötr' gibi ayırt edilmesi zor bir kategoride elde edilen rekabetçi sonuçlar, çalışmanın özgün bir yönünü göstermektedir. Bu çalışma, Türkçe gibi az kaynaklı dillerde duygu analizi ve sınıf dengesizliğinin derin öğrenme ile ele alınmasına katkı sunmaktadır.

Gelecekteki araştırmalar için potansiyel geliştirme alanları da mevcuttur. Geliştirilen LSTM tabanlı modelin, daha büyük ölçekli ve farklı alanlardan (örneğin, farklı ürün kategorileri, sosyal medya yorumları vb.) toplanmış veri kümeleri üzerinde test edilerek genelleme kapasitesinin daha detaylı bir şekilde değerlendirilmesi faydalı olacaktır. Ayrıca, güncel literatürde metin sınıflandırmada yüksek başarılar sergileyen Transformer mimarisine dayalı (örneğin, BERT, RoBERTa) veya özellikle Türkçe için geliştirilmiş ön-eğitilmiş dil modelleriyle (örneğin, BERTurk, TRT-BERT gibi) karşılaştırmalı analizlerin yapılması, önerilen modelin performansının daha geniş bir bağlamda yer edinmesine imkan sağlayacaktır. Mevcut üç temel duygu sınıfının ötesine geçerek, daha detaylı ve çok

katmanlı duygu sınıflarının (örneğin, memnuniyet, hayal kırıklığı, öfke, şaşkınlık, öneri vb.) tanımlandığı daha bir sınıflandırma yapısının hedeflenmesi, kullanıcı ifadelerinin daha derinlemesine anlaşılmasını sağlayabilir. Son olarak, metinlerdeki ironi, sarkazm ve mecaz gibi örtük anlamların daha başarılı bir şekilde tespit edilmesine yönelik özellik mühendisliği çalışmaları veya dikkat (attention) mekanizmalarının model mimarisine daha etkin bir şekilde entegre edilmesi, bu alandaki çalışmaları daha ileri bir seviyeye taşıyabilecek önemli araştırma konuları olarak öne çıkmaktadır.

KAYNAKLAR

- [1] M. Çabuk, F. Yücel, ve M. A. Toçoğlu, "Makine Öğrenmesi ile E-Ticaret Ürün Yorumlarının Otomatik Analizi," *Avrupa Bilim ve Teknoloji Dergisi*, Sayı 52, s. 110-121, Kasım 2023.
- [2] S. Kılıçer ve D. R. Samli, "E-Ticaret Sitelerindeki Türkçe Ürün Yorumları Üzerine Makine Öğrenmesi Algoritmaları ile Duygu Analizi," *Veri Bilim Dergisi*, cilt 6, sayı 2, s. 15-23, 2023.
- [3] Ö. F. Göçgün ve A. Onan, "Amazon Ürün Değerlendirmeleri Üzerinde Derin Öğrenme/Makine Öğrenmesi Tabanlı Duygu Analizi Yapılması," *Avrupa Bilim ve Teknoloji Dergisi*, Özel Sayı 24, s. 445-448, Nisan 2021.
- [4] A. J. J. ZADA ve A. ALBAYRAK, "Duygu Analizi ve Topluluk Öğrenmesi Yaklaşımları ile Kullanıcı Yorumlarının Analizi," *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, cilt 11, s. 1725-1732, 2023.
- [5] N. S. K. Klahid ve S. SAVAŞ, "Amazon veri setinde tüketici duygularını değerlendirmek için derin öğrenme yaklaşımı," *Pamukkale Univ. Muh. Bilim. Derg.*, (kabul tarihi Mart 2025, cilt, sayı ve sayfa numaraları basımda belli olacaktır).
- [6] M. Tabany ve M. Gueffal, "SVM Denetimli Makine Öğrenmesi Modeli Kullanılarak Duygu Analizi ve Sahte Amazon Yorumlarının Sınıflandırılması," *J. Adv. Inf. Technol.*, cilt 15, sayı 1, s. 49-58, Ocak 2024.
- [7] M. F. b. Harunasir, N. Palanichamy, S.-C. Haw, ve K.-W. Ng, "Denetimli Makine Öğrenmesi Modelleri ile Amazon Ürün İncelemelerinin Duygu Analizi," *J. Adv. Inf. Technol.*, cilt 14, sayı 4, s. 857-862, Ağustos 2023.
- [8] M. Haroon, Z. Alam, R. Kousar, J. Ahmad, ve F. Nasim, "E-ticaret Platformlarında Müşteri Yorumlarının Duygu Analizi: Bir Makine Öğrenmesi Yaklaşımı," *İşletme ve Ekonomi Bülteni*, cilt 13, sayı 3, s. 230-238, 2023.
- [9] M. F. TUNA, O. KAYNAR, ve M. Ş. AKDOĞAN, "Otellere İlişkin Çevrimiçi Geribildirimlerin Makine Öğrenmesi Yöntemleriyle Duygu Analizi," *İşletme Araştırmaları Dergisi*, cilt 13, sayı 3, s. 2232-2241, 2021.
- [10] S. Singhal, H. L. Majeed, H. M. Ibrahim, N. Jatana, C. Gupta, A. Kuma, et al., "Makine Öğrenmesi Kullanılarak Amazon Cep Telefonu İncelemelerinde Duygu Analizi," *Fusion Pract. Appl.*, cilt 18, sayı 01, s. 116-129, 2025.